

K-Means 聚类算法报告

石隽全 22307130485

1. 项目简介

本项目实现了 K-Means 聚类算法，并通过 K-Means++ 初始化方法优化了聚类中心的选择。目标是通过实现 K-Means 算法，并在 Iris 数据集上进行测试，分析不同 k 值下的聚类效果，比较 K-Means 和 K-Means++ 的收敛速度，并进行可视化展示。

2. K-Means 算法实现

K-Means 算法基于 Lloyd 算法，通过以下步骤实现：

1. 随机选择初始聚类中心。
2. 将每个数据点分配到最近的聚类中心。
3. 更新聚类中心为当前簇的均值。
4. 判断聚类中心是否收敛，如果未收敛，则返回第 2 步继续迭代。

3. K-Means++ 初始化方法


K-Means++ 是一种优化的聚类中心初始化方法，通过计算每个数据点到当前已选聚类中心的距离，并按概率选择新的聚类中心。这种方法可以有效避免传统 K-Means 中随机初始化聚类中心可能导致的局部最优问题。

4. 实验分析

4.1 聚类结果图

使用 K-Means 算法对 Iris 数据集进行聚类，并绘制聚类结果。图中标出了每个簇的中心（红色 'X'）。如图所示，每个簇的分布较为清晰，聚类中心的选取合理。


聚类结果图：



4.2 PCA 可视化图

通过 PCA（主成分分析）对高维数据进行降维，生成二维可视化图。图中不同的颜色代表不同的类别，聚类结果展示了数据在二维空间中的分布情况。


PCA 可视化图：



4.3 惯性图

绘制了惯性（每个点到其最近聚类中心的距离的平方和）随 k 值变化的图。可以看到，随着 k 值增加，惯性显著下降，且存在“肘部”现象，表明最佳聚类数目位于 3 附近。

惯性图：



5. 收敛速度比较

我们还比较了 K-Means 和 K-Means++ 初始化方法的收敛速度。K-Means++ 初始化方法通常能更快地收敛，因为它避免了随机初始化聚类中心带来的问题。

6. 结论

K-Means++ 相比于传统的 K-Means 初始化方法，能够更快地收敛，避免了聚类中心随机初始化带来的不稳定性。通过惯性图和聚类结果图的分析，我们选择了适当的聚类数，并验证了算法的有效性。