

垃圾短信分类项目报告

石隽全 22307130485

1. 项目目标

本项目的目标是实现一个基于决策树算法的垃圾短信分类模型。通过实现决策树算法，我们能够对短信进行分类，判断其是否为垃圾短信（spam）或正常短信（ham）。该模型使用 SMS Spam Collection 数据集进行训练和测试。

2. 数据分析与处理

2.1 数据集说明

数据集来自 SMS Spam Collection，包含以下两列：

- label: 短信的标签，'ham' 代表正常短信，'spam' 代表垃圾短信。
- message: 短信的内容，包含文本信息。

该数据集共有 5574 条短信，其中约 15% 为垃圾短信。我们使用了 spam.csv 文件进行实验，并将标签（ham, spam）映射为数字：ham -> 0, spam -> 1。

2.2 数据预处理

在数据预处理阶段，我进行了以下操作：

- 数据加载与清洗：使用 `pandas` 加载数据并删除包含 `NaN` 或空白字符串的行，确保数据质量。
- 标签转换：将 `ham` 标签映射为 `0`，`spam` 标签映射为 `1`，便于机器学习模型处理。
- 文本特征提取：使用 `CountVectorizer` 将短信内容转换为数值特征，采用词袋模型表示短信文本。
- 数据集划分：使用 `train\_test\_split` 将数据划分为 80% 训练集和 20% 测试集。

最终，返回了训练集和测试集的特征矩阵（`X\_train`，`X\_test`）和标签（`y\_train`，`y\_test`）。

3. 决策树实现

3.1 决策树算法

决策树是通过递归分割数据来实现分类的机器学习算法。模型基于信息增益进行特征选择，并不断划分数据，直到满足停止条件。

在本项目中，我实现了以下决策树的核心方法：

1. 信息熵 (Entropy)：衡量数据集的混乱程度。
2. 信息增益 (Information Gain)：用来选择最佳特征进行数据分裂。
3. 树的构建 (Build Tree)：递归地构建决策树，直到达到最大深度或所有数据已分类。
4. 预测 (Predict)：根据构建的决策树对新数据进行预测。

3.2 代码实现

我在 `Dtree.py` 中实现了 `Dtree` 类，该类包含了以下主要方法：

1. `fit(self, X, Y)`：训练模型，构建决策树。
2. `predict(self, X)`：使用训练好的决策树进行预测。

3.3 训练与预测

在 `main` 函数中，加载了处理过的数据集，调用了 `fit` 方法训练决策树，并使用 `predict` 方法对测试集进行预测。

```
def main(train_X, train_Y, test_X):  
    model = Dtree(max_depth=3)  
    model.fit(train_X, train_Y)  
    predictions = model.predict(test_X)  
    # 将预测结果写入文件  
    with open('predictions.txt', 'w') as f:  
        for prediction in predictions:  
            f.write(f"{prediction}\n") # 每个预测结果写入一行  
    return predictions
```

4. 模型优化

为了提高模型的性能并避免过拟合，我在模型中做了以下优化：

1. 限制树的最大深度：为了防止过拟合，我将决策树的最大深度设置为 3。
2. 数据清洗：去除了包含空值或空白的短信，保证了数据的质量。
3. 特征提取：使用 `CountVectorizer` 提取文本特征，将文本转化为数值数据供模型使用。

5. 模型评估

5.1 性能评估

在模型评估阶段，我们使用了以下评估指标：

1. 准确率：衡量模型正确预测的比例。
2. 精确率：表示模型预测为垃圾短信的样本中，实际为垃圾短信的比例。
3. 召回率：表示模型正确识别垃圾短信的比例。
4. F1-Score：精确率和召回率的调和平均值，综合评价模型的表现。
5. 混淆矩阵：用于详细展示模型的预测结果与真实标签之间的关系。

5.2 评估结果

在测试集上的评估结果如下：

准确率 (Accuracy) : 0.9471

精确率 (Precision) : 0.9099

召回率 (Recall) : 0.6733

F1-Score: 0.7739

混淆矩阵 (Confusion Matrix) :

```
[[955  10]
 [ 49 101]]
```

解释：

- 准确率为 94.71%，表明模型总体分类性能优秀。
- 精确率为 90.99%，即当模型预测为垃圾短信时，有 90.99% 的概率是正确的。
- 召回率为 67.33%，即模型能识别出 67.33% 的垃圾短信。
- F1-Score 综合考虑了精确率和召回率，得分为 0.7739，表明模型在这两个方面达到了一定的平衡。
- 混淆矩阵显示，955 条正常短信被正确预测，101 条垃圾短信被正确识别。

5.3 改进方向

尽管模型表现良好，但仍有提升空间：

1. 提高召回率：目前召回率为 67.33%，可以通过调整决策树的深度，或者使用其他机器学习模型（如随机森林或支持向量机）来提高召回率。
2. 特征选择与优化：当前使用了词袋模型 (CountVectorizer) 提取文本特征，未来可以考虑使用 TF-IDF 来替代，进一步优化模型的特征表示。
3. 超参数调优：可以通过 Grid Search 来调优决策树的超参数，如最大深度、最小样本分割数等，进一步提升模型表现。

6. 总结

本项目成功实现了一个基于决策树的垃圾短信分类模型，通过数据预处理、特征提取、决策树算法的训练和预测，模型能够有效地区分垃圾短信和正常短信。

模型的评估结果表明，决策树在准确率和精确度上表现优秀，但在召回率上还有提升空间。未来可以通过更复杂的特征提取方法和模型优化来进一步提升性能。